

Inteligencia Artificial a Gran Escala

Grao en Intelixencia Artificial

Práctica 5: MLlib (2025-2026)

1. El problema

En esta práctica, el objetivo es aplicar las técnicas de aprendizaje automático a gran escala utilizando **Spark MLlib** para resolver un problema de vuestra elección. La tarea consiste en elegir un problema y un conjunto de datos real lo bastante grande como para justificar el uso de Spark.

Se recomienda buscar conjuntos de datos en plataformas como Kaggle, Hugging Face Datasets, Google Dataset Search, o cualquier otro repositorio de datos públicos.

2. Objetivos

La tarea principal es que los grupos definan, resuelvan y presenten un problema de aprendizaje automático completo, siguiendo un esquema de trabajo riguroso. Para ello, deberán:

- Elegir un conjunto de datos y un problema (de regresión o clasificación) que se adapte al contexto de “Big Data”. Se recomienda que tenga un tamaño considerable (superior a medio millón de filas o 500 MB).
- Realizar un análisis exploratorio y preprocesar los datos.
- Entrenar y evaluar varios modelos de **MLlib**.
- Optimizar hiperparámetros.
- Analizar y argumentar la validez de los resultados obtenidos y las conclusiones.

Deberán adquirirse y/o reforzarse estas destrezas:

- Manipulación de RDDs y DataFrames.
- Uso de **MLlib** y pipelines de ML.
- Justificación de la metodología de trabajo.

3. Metodología y pasos a realizar

- **Definición del problema y dataset:** Cada grupo debe seleccionar un problema y un dataset. El profesor revisará la propuesta (presencialmente o por Teams/correo) para asegurar su idoneidad.
- **Preprocesamiento de datos:** Realizar un análisis preliminar del dataset y las transformaciones necesarias para el entrenamiento de los modelos.

- **Modelado:** Entrenar diferentes modelos de **MLlib** y evaluar su rendimiento utilizando métricas adecuadas para el problema. La elección de la(s) métrica(s) debe estar debidamente justificada en la memoria, explicando por qué son las más apropiadas para el problema escogido.
- Aplicar técnicas de optimización de hiperparámetros (como *GridSearch*) para mejorar el rendimiento del modelo.
- **Defensa presencial:** Cada grupo deberá solicitar una fecha de defensa, donde cualquiera de los miembros debe saber responder. Tendrán una duración aproximada de **10 minutos**. Durante la defensa se tratarán, entre otros, los siguientes aspectos:
 - El problema planteado y por qué es interesante.
 - El conjunto de datos y el preprocesamiento realizado.
 - Los modelos probados y los resultados obtenidos.
 - Las conclusiones y posibles mejoras futuras.

Nota: La nota final de la práctica no se basará únicamente en los resultados obtenidos, sino en la originalidad del problema, la calidad del trabajo y la justificación de la metodología. Adicionalmente, se tendrá en cuenta la capacidad del grupo para responder a las preguntas del profesorado durante la sesión de defensa.

4. Entrega

- La práctica debe realizarse en **grupos de 2 personas**.
- La entrega se realizará en el Campus Virtual.
- Documentos a entregar:
 - Un único fichero **.zip** que contenga:
 - Un archivo README.md que asegure la reproducibilidad del proyecto, indicando cómo ejecutar el código.
 - El código de Spark (**.py**) que permita replicar el proyecto de principio a fin de manera “end-to-end”, desde la carga de datos hasta la evaluación del modelo.
 - Opcionalmente, un notebook (Jupyter, Colab, etc.) con el análisis exploratorio de datos (EDA) y las pruebas iniciales.
 - Una memoria explicativa de no más de 6 páginas ¹ donde se describa la organización del código, se justifique el planteamiento y se analicen los resultados.
- Los ficheros deberán ser entregados por **SÓLO UN** miembro del equipo de prácticas.
- No se admiten entregas pasada la fecha indicada.

Fecha límite de entrega: 28 de abril de 2026 (hasta las 15:30).

¹Formato Lecture Notes in Computer Science disponible en <https://es.overleaf.com/latex/templates/springer-lecture-notes-in-computer-science/kzwvpvhwnvfj>